

Projet analyse factorielle

VUACHET Luigi

Décembre 2023

1 Importation des données et représentation des stations

Nous importons les données météorologiques de stations françaises via un lien avec la commande :

```
clim <- read.csv("https://userpage.fu-berlin.de/soga/300/30100_data_ets/Climfrance.csv", sep = ";")
```

On remarque que les colonnes p_mean et altitude sont mal formatées. Par conséquent, nous utilisons une commande pour nous assurer que toutes les valeurs de ces colonnes sont numériques :

```
clim[, "p_mean"] <- as.numeric(gsub(" ", "", clim[, "p_mean"]))
clim[, "altitude"] <- as.numeric(gsub(" ", "", clim[, "altitude"]))
```


Ainsi, nous avons le tableau suivant :

station	altitude	lat	lon	t_mean	t_max	t_min	relhumidity	p_mean	p_max24h	rainydays	sun_shine_hperys
Marseille	3	43.45	5.21	14.2	24.4	2.3	68	546	86	76	2764
Nice	5	43.66	7.20	14.8	23.7	7.1	72	862	147	86	2775
Cherbourg	8	49.65	-1.63	11.4	19.2	4.3	80	931	62	171	1608
Bastia (Korsika)	10	42.55	9.48	14.9	25.0	7.5	70	735	201	91	2603
Nantes	26	47.16	-1.61	11.7	22.6	1.6	82	741	62	172	1952
Rennes	35	48.06	-1.71	11.3	22.1	0.6	82	669	45	168	1805
Belle-Ile/Talut	37	47.30	-3.21	12.3	19.9	4.5	89	637	81	147	2111
Perpignan	43	42.73	2.86	12.5	26.2	5.4	66	639	186	85	2644
Lille	44	50.73	3.10	9.7	21.3	-0.2	82	637	49	171	1574
Bordeaux	47	44.83	-0.70	12.3	24.9	0.6	81	900	54	162	2052
Paris (Le Bourget)	52	48.96	2.45	10.9	23.2	2.1	77	585	56	164	1779
Monaco	55	43.71	7.41	16.4	22.2	10.4	73	796	111	58	2331
Dinard	63	48.60	-2.08	11.0	20.6	2.3	82	726	42	174	2007
Biarritz	69	43.46	-1.53	13.7	25.5	3.5	78	1475	153	177	1952
Boulogne-sur-Mer	73	50.73	1.60	10.4	19.6	2.7	83	599	44	170	2228
Montélimar	73	44.58	4.73	12.9	25.0	2.1	70	998	181	108	2505
Reims	94	49.30	4.33	10.2	22.4	-1.6	79	598	47	164	1729
Sète	94	43.40	3.70	14.0	24.4	6.4	73	615	108	73	2805
Brest	98	48.45	-4.41	10.8	19.7	2.3	85	1126	57	201	1729
Tours	98	47.41	0.76	11.4	23.2	0.8	79	689	74	157	1826
Strasbourg	149	48.55	7.63	9.7	22.6	-1.4	78	607	54	158	1685
Toulouse	151	43.61	1.36	12.5	24.5	1.2	79	659	78	138	2080
Nevers	176	47.00	3.10	10.6	21.8	-1.8	78	772	117	166	2102
Lyon	200	45.71	4.95	11.4	23.7	0.3	76	813	89	145	2072
Gourdon	205	44.75	1.38	12.2	25.1	-0.1	77	801	92	157	1972
Auxerre	207	47.80	3.55	10.8	26.6	-0.8	78	643	46	159	1925
Nancy	212	48.70	6.23	9.7	21.2	-2.5	81	712	85	161	1648
Dijon	220	47.26	5.91	10.5	22.7	-0.1	76	739	110	147	2049
Grenoble	223	45.16	5.73	11.0	24.0	-0.5	77	985	135	144	2085
Limoges	282	45.81	1.28	10.6	23.5	-2.3	77	934	62	165	1885
Clermont-Ferrand	329	45.80	3.15	10.9	24.6	-2.3	72	563	55	132	1990
Millau	409	44.10	3.05	11.6	23.9	-0.1	71	730	137	144	2127
Belfort	422	47.63	6.86	9.5	22.1	-1.0	80	1038	68	174	1845
Le Puy-en-Velay	714	45.05	3.90	9.3	22.4	-2.8	74	635	76	148	2061
Mont-Ventoux	1212	44.16	5.28	3.6	12.8	-6.3	78	966	118	109	2286
Pic-du-Midi	2860	42.93	0.15	-1.2	8.6	-11.8	73	1013	73	175	2204

Ensuite, nous utilisons le code suivant afin de représenter les stations météorologiques sur la carte de la France :

```
G1 <- raster :: getData(country = "France", level = 1)
library(ggplot2)
ggplot() +
  geom_polygon(data = G1, aes(x = long, y = lat, group = group), colour =
    "grey10", fill = "#fff7bc"
  ) +
  geom_point(data = clim, aes(x = lon, y = lat), alpha = .5, size = 2, color =
    "blue"
  ) +
  theme_bw() +
  xlab("Longitude") +
  ylab("Latitude") +
  coord_map()
```

Représentation des stations météorologiques sur la carte de la France



2 Analyse des composantes principales

Nous utilisons le code suivant afin de déterminer combien il faut de composantes principales pour expliquer 80% de la variabilité totale :


```
# on calcul les valeurs propres et vecteurs propres de la matrice de covariance
eigen_climcr <- eigen(cov_climcr)

#On calcul la proportion de variance expliquée
exp_prop_eig <- eigen_climcr$values/sum(eigen_climcr$values)

# On trace :
# La proportion de variance expliquée
# La proportion cumulée de variance expliquée

plot(exp_prop_eig,ylab="Proportion de variance expliquée",xlab="Composante principale",type="b")
plot(cumsum(exp_prop_eig),ylab="Proportion cumulée de variance expliquée",xlab="Composante principale",type="b")
```

Le code permet de tracer les courbes suivantes :



Graphiquement, on remarque que les 3 premières composantes principales expliquent au moins 80% de la variance totale. On peut le voir plus en détails dans le tableau ci-dessous (qui ne prend en compte que les trois premières composantes principales).

Composante principale	Proportion de variance expliquée	Proportion cumulée de variance expliquée
1	0.4271415	0.4271415
2	0.267518367	0.6946599
3	0.121833158	0.8164930

3 Interprétations des deux premières composantes principales

Afin d'interpréter les deux composantes principales. Nous allons utiliser le code suivant :

```
# Faire l'ACP
library("FactoMineR")
res <- PCA(clim[,c(2:12)])

res$var$coord
res$var$cos2
res$var$contrib

library("factoextra")
# Représentation des individus dans le plan principal
fviz_pca_ind(res,col.ind = "black")
# Représentation des variables dans le plan principal
fviz_pca_var(res,col.var = "red")
```


Nous obtenons trois matrices (la première est la matrice des coordonnées).

```
> res$var$coord
      Dim.1      Dim.2      Dim.3      Dim.4      Dim.5
altitude -0.3730550 -0.9019405 -0.0291667546 -0.08598037 -0.05654939
lat       -0.6751559  0.5604621 -0.2704576495  0.08135072  0.28023035
lon       0.5344734 -0.2507935 -0.4966337858  0.49841377  0.35696526
t_mean    0.6937274  0.6842995  0.1488748943 -0.02293347 -0.02496497
t_max     0.5837362  0.6097586  0.0001868823  0.34446649 -0.38538527
t_min     0.6603664  0.5795905  0.2059236738 -0.26690881  0.25342811
relhumidity -0.7392064  0.4670423  0.1827920247 -0.16903019  0.24667104
p_mean    -0.1132114 -0.2790364  0.8724235554  0.27944608  0.15758921
p_max24h  -0.7590421 -0.3212293  0.3374029011  0.19245519  0.15122733
rainydays -0.8842597  0.2148840  0.2158112479  0.22267163 -0.14177951
sun_shine_hperys 0.8015589 -0.3617187  0.0015001509 -0.36796300  0.01530196

> res$var$cos2
      Dim.1      Dim.2      Dim.3      Dim.4      Dim.5
altitude 0.13917004 0.81349663 8.506996e-04 0.007392624 0.0031978332
lat      0.45583550 0.31411782 7.314734e-02 0.006617939 0.0785290489
lon      0.28566182 0.06289738 2.466451e-01 0.248416284 0.1274242000
t_mean   0.48125765 0.46826580 2.216373e-02 0.000525944 0.0006232498
t_max    0.34074797 0.37180560 3.492499e-08 0.118657162 0.1485218071
t_min    0.43608375 0.33592515 4.240456e-02 0.071240315 0.0642258056
relhumidity 0.54642607 0.21812853 3.341292e-02 0.028571206 0.0608466010
p_mean   0.01281683 0.07786133 7.611229e-01 0.078090114 0.0248343593
p_max24h 0.57614485 0.10318828 1.138407e-01 0.037039001 0.0228697065
rainydays 0.78191517 0.04617514 4.657449e-02 0.049582655 0.0201014281
sun_shine_hperys 0.64249672 0.13084039 2.250453e-06 0.135396767 0.0002341499

> res$var$contrib
      Dim.1      Dim.2      Dim.3      Dim.4      Dim.5
altitude 2.9619746 27.644546 6.347724e-02 0.94591688 0.57993938
lat      9.7016075 10.674469 5.458086e+00 0.84679273 14.24154563
lon      6.0797785 2.137402 1.840409e+01 31.78589181 23.10886971
t_mean   10.2426706 15.912783 1.653807e+00 0.06729671 0.11302875
t_max    7.2521843 12.634837 2.606022e-06 15.18267502 26.93500205
t_min    9.2812285 11.415534 3.164130e+00 9.11549314 11.64759733
relhumidity 11.6296586 7.412525 2.493195e+00 3.65580404 11.03476556
p_mean   0.2727823 2.645913 5.679323e+01 9.99195332 4.50380676
p_max24h 12.2621675 3.506583 8.494532e+00 4.73929356 4.14750940
rainydays 16.6416046 1.569141 3.475281e+00 6.34430594 3.64547144
sun_shine_hperys 13.6743430 4.446267 1.679236e-04 17.32457685 0.04246399
```

Représentations des individus et des variables sur le plan principal :



Nous remarquons *rainydays* et *sun_shine_hperyrs* sont les deux variables les plus fortement corrélées à la première composante principale (les mieux représentées). De plus, elles contribuent respectivement environ 16,6% et 13,6% de la variabilité de la composante.

De même, *altitude* est la variable la plus fortement corrélée à la deuxième composante principale. Elle contribue pour environ 27,6% de la variabilité de la composante.

On en déduit que la première composante principale est expliquée par les variables *rainydays* et *sun_shine_hperyrs*. La deuxième composante principale est expliquée par *altitude*.